

Estatística I

Prof. Fernando de Souza Bastos
fernando.bastos@ufv.br

Departamento de Estatística
Universidade Federal de Viçosa
Campus UFV - Viçosa




Sumário


- 1 Regressão Linear Simples
- 2 Coeficiente de Correlação
- 3 Modelo de Regressão
- 4 Estimação por Mínimos Quadrados
- 5 Teste de Hipótese para Regressão Linear Simples
- 6 Análise de Variância (ANOVA) para a Regressão Linear Simples

Em certas situações podemos estar interessados em descrever a relação entre duas variáveis, e também prever o valor de uma a partir de outra. Por exemplo, se sabemos a altura de um certo estudante, mas não o seu peso, qual seria um bom chute para o peso deste estudante?


```
x = c(176, 154, 138, 196, 132, 176, 181, 169, 150, 175)
y = c(82, 49, 53, 112, 47, 69, 77, 71, 62, 78)
plot(x,y,xlab="Altura (cm)",ylab="Peso (kg)",
     pch=16, ylim = c(40,115))
lines(x, fitted(lm(y ~ x)), col="blue")
```



```
doses <- c(0, 50, 100, 150, 200, 250, 300)
resp <- c(148.6, 153.6, 154.5, 154.9, 158, 160, 154.4)
reglin <- lm(resp ~ doses)
plot(doses, resp) #(variável indep. primeiro)
lines(doses, fitted(reglin), col="blue")#acrescenta
a reta de regressão ajustada
```



```
#Tempo de espera entre erupções e a duração da erupção  
fit <- lm(waiting~eruptions, data=faithful)  
plot(faithful)  
lines(faithful$eruptions, fitted(fit), col="blue")
```



Objetivos:

Estudar a relação linear entre duas variáveis quantitativas. Exemplos:

- ❶ Altura dos pais e altura dos filhos;

Objetivos:

Estudar a relação linear entre duas variáveis quantitativas. Exemplos:

- (i) Altura dos pais e altura dos filhos;
- (ii) Renda semanal e despesas de consumo;

Objetivos:

Estudar a relação linear entre duas variáveis quantitativas. Exemplos:

- (i) Altura dos pais e altura dos filhos;
- (ii) Renda semanal e despesas de consumo;
- (iii) Variação dos salários e taxa de desemprego;

Objetivos:

Estudar a relação linear entre duas variáveis quantitativas. Exemplos:

- ❶ Altura dos pais e altura dos filhos;
- ❷ Renda semanal e despesas de consumo;
- ❸ Variação dos salários e taxa de desemprego;
- ❹ Demanda dos produtos de uma firma e publicidade;

Objetivos:

Estudar a relação linear entre duas variáveis quantitativas. Exemplos:

- ❶ Altura dos pais e altura dos filhos;
- ❷ Renda semanal e despesas de consumo;
- ❸ Variação dos salários e taxa de desemprego;
- ❹ Demanda dos produtos de uma firma e publicidade;

Sob dois pontos de vista:

- ❶ Explicitando a forma dessa relação: regressão.

Objetivos:

Estudar a relação linear entre duas variáveis quantitativas. Exemplos:

- ❶ Altura dos pais e altura dos filhos;
- ❷ Renda semanal e despesas de consumo;
- ❸ Variação dos salários e taxa de desemprego;
- ❹ Demanda dos produtos de uma firma e publicidade;

Sob dois pontos de vista:

- ❶ Explicitando a forma dessa relação: regressão.
- ❷ Quantificando a força dessa relação: correlação.

Importante:

Uma relação estatística por si própria não implica uma causa, para atribuir causa, devemos invocar alguma teoria!

Importante:

Uma relação estatística por si própria não implica uma causa, para atribuir causa, devemos invocar alguma teoria!

Uma regressão espúria é uma relação estatística existente entre duas variáveis, mas onde não existe nenhuma relação causa-efeito entre elas. Essa relação estatística pode ocorrer por pura coincidência ou por causa de uma terceira variável. Ou seja, neste último caso, pode ocorrer que as variáveis X e Y sejam correlacionadas porque ambas são causadas por uma terceira variável Z .

Só porque (A) acontece juntamente com (B) não significa que (A) causa (B). Determinar se existe de fato uma relação de causalidade requer investigação adicional pois podem acontecer cinco situações:

- ❶ (A) causa realmente (B);

Só porque (A) acontece juntamente com (B) não significa que (A) causa (B). Determinar se existe de fato uma relação de causalidade requer investigação adicional pois podem acontecer cinco situações:

- ❶ (A) causa realmente (B);
- ❷ (B) pode ser a causa de (A);

Só porque (A) acontece juntamente com (B) não significa que (A) causa (B). Determinar se existe de fato uma relação de causalidade requer investigação adicional pois podem acontecer cinco situações:

- ❶ (A) causa realmente (B);
- ❷ (B) pode ser a causa de (A);
- ❸ Um terceiro factor (C) pode ser causa tanto de (A) como de (B);

Só porque (A) acontece juntamente com (B) não significa que (A) causa (B). Determinar se existe de fato uma relação de causalidade requer investigação adicional pois podem acontecer cinco situações:

- ❶ (A) causa realmente (B);
- ❷ (B) pode ser a causa de (A);
- ❸ Um terceiro factor (C) pode ser causa tanto de (A) como de (B); Pode ser uma combinação das três situações anteriores. Por exemplo, (A) causa (B) e ao mesmo tempo (B) causa também (A);

Só porque (A) acontece juntamente com (B) não significa que (A) causa (B). Determinar se existe de fato uma relação de causalidade requer investigação adicional pois podem acontecer cinco situações:

- ❶ (A) causa realmente (B);
- ❷ (B) pode ser a causa de (A);
- ❸ Um terceiro factor (C) pode ser causa tanto de (A) como de (B); Pode ser uma combinação das três situações anteriores. Por exemplo, (A) causa (B) e ao mesmo tempo (B) causa também (A);
- ❹ A correlação pode ser apenas uma coincidência, ou seja, os dois eventos não têm qualquer relação para além do fato de ocorrerem ao mesmo tempo.


Exemplos:

“Quanto maiores são os pés de uma criança, maior a capacidade para resolver problemas de matemática. Portanto, ter pés grandes faz ter melhores notas em matemática”.


Exemplos:

“Vários estudos apontavam inicialmente que as mulheres em menopausa que recebiam terapia de substituição hormonal (TSH) tinham também um menor risco de doença coronária, o que levou à ideia de que a TSH conferia protecção contra a doença coronária. No entanto, estudos controlados e randomizados (mais rigorosos), feitos posteriormente, mostraram que a TSH causava na verdade um pequeno mas significativo aumento do risco de doença coronária. Uma reanálise dos estudos revelou que as mulheres que recebiam a TSH tinham também uma maior probabilidade de pertencer a uma classe socioeconómica superior, com melhor dieta e hábitos de exercício. A utilização da TSH e a baixa incidência de doença coronária não eram causa e efeito, mas o fruto de uma causa comum”.

“Quanto menos as pessoas se divorciam em Maine (EUA), menor fica o consumo de margarina naquele Estado”.

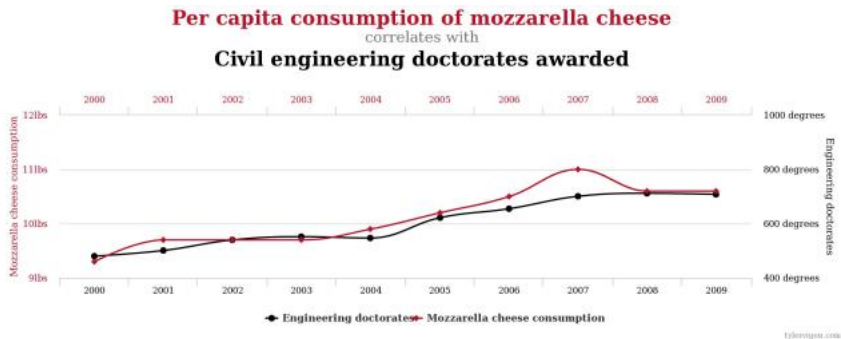


Deveríamos banir Nicolas Cage do cinema para evitar o afogamento de pessoas? O primeiro gráfico nos dá o número de pessoas afogadas (linha vermelha) e as aparições do Nicolas Cage em filmes (linha preta).



tylervigen.com

Consumo de muçarela (linha vermelha) e doutorados obtidos em engenharia civil (linha preta)



Coefficiente de Correlação Amostral de Pearson

O coeficiente de correlação (r ou $\hat{\rho}$) mede o grau de associação linear entre duas variáveis aleatórias X e Y . Considere,

$$\begin{array}{c|cccc} X_i & X_1 & X_2 & \cdots & X_n \\ \hline Y_i & Y_1 & Y_2 & \cdots & Y_n \end{array}$$

Assim, o coeficiente de correlação entre X e Y é dado por:

$$r_{XY} = \frac{S_{XY}}{\sqrt{S_X^2 \cdot S_Y^2}} = \frac{\frac{SPD_{XY}}{n-1}}{\sqrt{\frac{SQD_X}{n-1} \cdot \frac{SQD_Y}{n-1}}} = \frac{SPD_{XY}}{\sqrt{SQD_X \cdot SQD_Y}}$$

Temos,

$$SPD_{XY} = \sum_{i=1}^n X_i Y_i - \frac{\left(\sum_{i=1}^n X_i\right) \left(\sum_{i=1}^n Y_i\right)}{n}$$

Temos,

$$SPD_{XY} = \sum_{i=1}^n X_i Y_i - \frac{\left(\sum_{i=1}^n X_i\right) \left(\sum_{i=1}^n Y_i\right)}{n}$$

$$SQD_X = \sum_{i=1}^n X_i^2 - \frac{\left(\sum_{i=1}^n X_i\right)^2}{n} \quad \text{e} \quad SQD_Y = \sum_{i=1}^n Y_i^2 - \frac{\left(\sum_{i=1}^n Y_i\right)^2}{n}$$

Temos,

$$SPD_{XY} = \sum_{i=1}^n X_i Y_i - \frac{\left(\sum_{i=1}^n X_i\right) \left(\sum_{i=1}^n Y_i\right)}{n}$$

$$SQD_X = \sum_{i=1}^n X_i^2 - \frac{\left(\sum_{i=1}^n X_i\right)^2}{n} \quad \text{e} \quad SQD_Y = \sum_{i=1}^n Y_i^2 - \frac{\left(\sum_{i=1}^n Y_i\right)^2}{n}$$

$$-1 \leq r_{XY} \leq 1$$

Exemplo

Amostra A	4	8	3	9	7	5
Amostra B	1	5	2	14	3	11

Temos,

$$SPD_{AB} = \sum_{i=1}^n A_i B_i - \frac{\left(\sum_{i=1}^n A_i\right) \left(\sum_{i=1}^n B_i\right)}{n}$$

Exemplo

Amostra A	4	8	3	9	7	5
Amostra B	1	5	2	14	3	11

Temos,

$$SPD_{AB} = \sum_{i=1}^n A_i B_i - \frac{\left(\sum_{i=1}^n A_i\right) \left(\sum_{i=1}^n B_i\right)}{n}$$

$$SQD_A = \sum_{i=1}^n A_i^2 - \frac{\left(\sum_{i=1}^n A_i\right)^2}{n} \quad \text{e} \quad SQD_B = \sum_{i=1}^n B_i^2 - \frac{\left(\sum_{i=1}^n B_i\right)^2}{n}$$

Exemplo

Assim,

$$SPD_{AB} = 252 - \frac{(36)(36)}{6} = 36$$

Exemplo

Assim,

$$SPD_{AB} = 252 - \frac{(36)(36)}{6} = 36$$

$$SQD_A = 244 - \frac{(36)^2}{6} = 28 \quad \text{e} \quad SQD_B = 356 - \frac{(36)^2}{6} = 140$$

Exemplo

Assim,

$$SPD_{AB} = 252 - \frac{(36)(36)}{6} = 36$$

$$SQD_A = 244 - \frac{(36)^2}{6} = 28 \quad \text{e} \quad SQD_B = 356 - \frac{(36)^2}{6} = 140$$

$$r_{AB} = \frac{SP_{AB}}{\sqrt{SQD_A SQD_B}} = \frac{36}{\sqrt{28 \cdot 140}} = 0,5750$$

De forma geral, um modelo estatístico pode ser escrito da seguinte forma:

$$Y = \text{componente determinística} + \text{componente aleatória}$$

existem diversas maneiras de especificar essas componentes. Começaremos com uma regressão linear simples.

Uma regressão linear simples tem como objetivo aproximar uma variável resposta Y através de uma função linear de uma variável de interesse, ou seja,

$$Y = f(X, \beta) + \varepsilon = \beta_0 + \beta_1 X + \varepsilon$$

No qual assume-se que:

❶ $E(\varepsilon) = 0$

Uma regressão linear simples tem como objetivo aproximar uma variável resposta Y através de uma função linear de uma variável de interesse, ou seja,

$$Y = f(X, \beta) + \varepsilon = \beta_0 + \beta_1 X + \varepsilon$$

No qual assume-se que:

- ❶ $E(\varepsilon) = 0$
- ❷ $V(\varepsilon) = \sigma^2$ (Homocedasticidade)

Uma regressão linear simples tem como objetivo aproximar uma variável resposta Y através de uma função linear de uma variável de interesse, ou seja,

$$Y = f(X, \beta) + \varepsilon = \beta_0 + \beta_1 X + \varepsilon$$

No qual assume-se que:

- (i) $E(\varepsilon) = 0$
- (ii) $V(\varepsilon) = \sigma^2$ (Homocedasticidade)
- (iii) $Cov(\varepsilon_i, \varepsilon_j) = 0$

em outras palavras, os erros tem média zero, variância constante e são não correlacionados.

A variável preditora X pode vir de diversas fontes:

- inputs quantitativos (valores reais, medidas)
- transformação de variável quantitativas ($\log()$, $\sqrt{()}$, etc)
- inputs qualitativos ("dummy" e.x. gênero, classes)

Dessa forma, um modelos de regressão consiste em 4 passos:

- 1 Escolher o componente determinístico do modelo;

A variável preditora X pode vir de diversas fontes:

- inputs quantitativos (valores reais, medidas)
- transformação de variável quantitativas ($\log()$, $\sqrt{()}$, etc)
- inputs qualitativos ("dummy" e.x. gênero, classes)

Dessa forma, um modelos de regressão consiste em 4 passos:

- 1 Escolher o componente determinístico do modelo;
- 2 Especificar a distribuição do erro;

A variável preditora X pode vir de diversas fontes:

- inputs quantitativos (valores reais, medidas)
- transformação de variável quantitativas ($\log()$, $\sqrt{()}$, etc)
- inputs qualitativos ("dummy" e.x. gênero, classes)

Dessa forma, um modelos de regressão consiste em 4 passos:

- 1 Escolher o componente determinístico do modelo;
- 2 Especificar a distribuição do erro;
- 3 Utilizar os dados para estimar os parâmetros do modelo;

A variável preditora X pode vir de diversas fontes:

- inputs quantitativos (valores reais, medidas)
- transformação de variável quantitativas ($\log()$, $\sqrt{()}$, etc)
- inputs qualitativos ("dummy" e.x. gênero, classes)

Dessa forma, um modelos de regressão consiste em 4 passos:

- 1 Escolher o componente determinístico do modelo;
- 2 Especificar a distribuição do erro;
- 3 Utilizar os dados para estimar os parâmetros do modelo;
- 4 Avaliar o modelo estatístico;

Os dados para a análise de regressão e correlação simples são da forma:

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$$


Com base nos dados constrói-se o diagrama de dispersão, que deve exibir uma tendência linear para que se possa usar a regressão linear. Este diagrama permite decidir empiricamente:

- Se um relacionamento linear entre as variáveis X e Y deve ser assumido;
- Se o grau de relacionamento linear entre as variáveis é forte ou fraco, conforme o modo como se situam os pontos em redor de uma reta imaginária que passa através do enxame de pontos.

#Encontre o modelo de Regressão Linear que melhor se ajusta aos dados

```
x = c(176, 154, 138, 196, 132, 176, 181, 169, 150, 175)
```

```
y = c(82, 49, 53, 112, 47, 69, 77, 71, 62, 78)
```



```
#Encontre o modelo de Regressão Linear que melhor se  
ajusta aos dados  
x <- c(176, 154, 138, 196, 132, 176, 181, 169, 150, 175)  
y <- c( 82,  49,  53, 112,  47,  69,  77,  71,  62,  78)  
Reg <- lm(y~x)  
Reg  
  
Call:  
lm(formula = y ~ x)  
  
Coefficients:  
(Intercept)              x  
   -70.4627         0.8528
```

```
#library(texreg)
summary(Reg)

lm(formula = y ~ x)
Residuals:
      Min       1Q   Median       3Q      Max
-11.8746  -5.8428   0.7893   4.8001  15.3061
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  -70.4627    24.0148  -2.934 0.018878 *
x              0.8528     0.1448   5.889 0.000366 ***
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.'
Residual standard error: 8.854 on 8 degrees of freedom
Multiple R-squared:  0.8126, Adjusted R-squared:  0.7891
F-statistic: 34.68 on 1 and 8 DF,  p-value: 0.0003662
```

	Model 1
(Intercept)	-70.46* (24.01)
x	0.85*** (0.14)
R^2	0.81
Adj. R^2	0.79
Num. obs.	10
RMSE	8.85

*** $p < 0.001$, ** $p < 0.01$, * $p < 0.05$

Tabela: Statistical models

R^2

Representa a porcentagem de variação na resposta que é explicada pelo modelo. Ele é calculado como 1 menos a razão da soma dos quadrados dos erros (que é a variação que não é explicada pelo modelo) pela soma total dos quadrados (que é a variação total no modelo).

R^2

Representa a porcentagem de variação na resposta que é explicada pelo modelo. Ele é calculado como 1 menos a razão da soma dos quadrados dos erros (que é a variação que não é explicada pelo modelo) pela soma total dos quadrados (que é a variação total no modelo).

R^2

Use R^2 para determinar se o modelo se ajusta bem aos dados. Quanto mais alto o valor de R^2 melhor o modelo ajusta seus dados. O valor de R^2 está sempre entre 0 e 100%.

Considere as seguintes questões ao interpretar o valor de R^2 :

O R^2 sempre aumenta quando você adiciona mais preditores a um modelo. Por exemplo, o melhor modelo de cinco preditores terá sempre um R^2 que é pelo menos tão elevado quanto o melhor modelo de quatro preditores. Portanto, R^2 é mais útil quando for comparado a modelos do mesmo tamanho.

Considere as seguintes questões ao interpretar o valor de R^2 :

O R^2 sempre aumenta quando você adiciona mais preditores a um modelo. Por exemplo, o melhor modelo de cinco preditores terá sempre um R^2 que é pelo menos tão elevado quanto o melhor modelo de quatro preditores. Portanto, R^2 é mais útil quando for comparado a modelos do mesmo tamanho.

Amostras pequenas não fornecem uma estimativa precisa da força da relação entre a resposta e os preditores. Se você precisar que R^2 seja mais exato, deve usar uma amostra maior (geralmente, 40 ou mais).

R^2 é apenas uma medida de o quão bem o modelo ajusta os dados. Mesmo quando um modelo tem um R^2 elevado, você deve verificar os gráficos de resíduos para conferir se o modelo satisfaz os pressupostos do modelo.

Estimação por Mínimos Quadrados

$$e_i = Y_i - \beta_0 - \beta_1 X_i, i = 1, \dots, n$$

\Rightarrow

$$e_i^2 = \left(Y_i - \beta_0 - \beta_1 X_i \right)^2, i = 1, \dots, n$$

\Rightarrow

$$f(\beta_0, \beta_1) = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n \left(Y_i - \beta_0 - \beta_1 X_i \right)^2$$

Estimação por Mínimos Quadrados

Usando a primeira e a segunda derivada podemos obter os valores que minimizam a soma de quadrados, são eles:

$$\hat{\beta}_1 = \frac{\sum x_i y_i - \frac{\sum x_i \sum y_i}{n}}{\sum x_i^2 - \frac{(\sum x_i)^2}{n}} = \frac{SPD_{xy}}{SQD_x} \text{ e } \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

Estimação por Mínimos Quadrados

Usando a primeira e a segunda derivada podemos obter os valores que minimizam a soma de quadrados, são eles:

$$\hat{\beta}_1 = \frac{\sum x_i y_i - \frac{\sum x_i \sum y_i}{n}}{\sum x_i^2 - \frac{(\sum x_i)^2}{n}} = \frac{SPD_{xy}}{SQD_x} \text{ e } \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

Uma vez obtida estas estimativas, podemos escrever a equação estimada:

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X_i$$

Estimação por Mínimos Quadrados

O R^2 é obtido por

$$R^2 = \frac{SQReg}{SQTotal} = \frac{\hat{\beta}_1 SPD_{xy}}{SQD_y}$$

Estimação por Mínimos Quadrados

O R^2 é obtido por

$$R^2 = \frac{SQReg}{SQTotal} = \frac{\hat{\beta}_1 SPD_{xy}}{SQD_y}$$

O R^2 indica a proporção (ou %) da variação de Y que é “explicada” pela regressão, ou quanto da variação na variável dependente Y está sendo “explicada” pela variável independente X .

Teste de Hipótese para Regressão Linear Simples

A equação de regressão estimada apenas estabelece uma relação funcional entre a variável dependente e a variável independente, para representar o fenômeno em estudo. Portanto, a simples obtenção da equação estimada não responde ao pesquisador se a variação da variável independente influencia significativamente na variação da variável dependente. Assim, faz-se necessário, realizar um teste estatístico para as estimativas dos coeficientes da regressão estimada. Um teste que pode ser realizado é o teste F da Análise de Variância e/ou teste t.

Teste de Hipótese para Regressão Linear Simples

Vamos proceder o teste t para avaliar a significância da regressão, ou seja, vamos testar se $\beta_1 = 0$ contra $\beta_1 \neq 0$.

$$\begin{cases} H_0 : \beta_1 = 0 \\ H_1 : \beta_1 \neq 0 \end{cases}$$

$$t_{cal} = \frac{\hat{\beta}_1}{\sqrt{\hat{V}(\hat{\beta}_1)}}, \text{ em que } \hat{V}(\hat{\beta}_1) = \frac{\hat{\sigma}^2}{SQD_x} \text{ e } \hat{\sigma}^2 = \frac{SQResiduo}{n - 2}$$

Regra de Decisão: Se $|t_{cal}| \geq |t_{\alpha/2}(n - 2)| \Rightarrow$ rejeita-se H_0 .

Teste de Hipótese para Regressão Linear Simples

Não rejeitar H_0 é equivalente a concluir que não existe relação linear entre X e Y . Por outro lado, rejeitar H_0 significa que X é importante para explicar a variabilidade de Y .

Análise de Variância (ANOVA) para a Regressão Linear Simples

O método da ANOVA consiste em fazer uma partição da variabilidade total da variável resposta Y em outros componentes de acordo com o modelo e o teste a ser feito. Assim, a seguinte identidade pode ser verificada:

$$\sum (Y_i - \bar{Y})^2 = \sum (\hat{Y}_i - \bar{Y})^2 + \sum (Y_i - \hat{Y})^2,$$

ou, em outras palavras

$$SQ_{Total} = SQ_{Regressao} + SQ_{Residuo},$$

Análise de Variância (ANOVA) para a Regressão Linear Simples

$$SQTotal = SQRegressao + SQResiduo,$$

em que,

- $SQTotal = \text{Variação Total em } Y = SQD_Y$

Análise de Variância (ANOVA) para a Regressão Linear Simples

$$SQTotal = SQRegressao + SQResiduo,$$

em que,

- $SQTotal$ = Variação Total em $Y = SQD_Y$
- $SQRegressao$ é a variação em Y explicada pela regressão ajustada, ou seja:

Análise de Variância (ANOVA) para a Regressão Linear Simples

$$SQTotal = SQRegressao + SQResiduo,$$

em que,

- $SQTotal$ = Variação Total em $Y = SQD_Y$
- $SQRegressao$ é a variação em Y explicada pela regressão ajustada, ou seja:
- $SQRegressao = \hat{\beta}_1 SPD_{XY}$ de tal forma que,

Análise de Variância (ANOVA) para a Regressão Linear Simples

$$SQTotal = SQRegressao + SQResiduo,$$

em que,

- $SQTotal$ = Variação Total em $Y = SQD_Y$
- $SQRegressao$ é a variação em Y explicada pela regressão ajustada, ou seja:
- $SQRegressao = \hat{\beta}_1 SPD_{XY}$ de tal forma que,
- $SQResiduo$ é igual a variação não explicada pela regressão, isto é:

Análise de Variância (ANOVA) para a Regressão Linear Simples

$$SQTotal = SQRegressao + SQResiduo,$$

em que,

- $SQTotal$ = Variação Total em $Y = SQD_Y$
- $SQRegressao$ é a variação em Y explicada pela regressão ajustada, ou seja:
- $SQRegressao = \hat{\beta}_1 SPD_{XY}$ de tal forma que,
- $SQResiduo$ é igual a variação não explicada pela regressão, isto é:
- $SQResiduo = SQD_Y - \hat{\beta}_1 SPD_{XY}$.

Análise de Variância (ANOVA) para a Regressão Linear Simples

Baseado nos cálculos acima podemos montar o seguinte quadro de ANOVA:






FV	GL	SQ	QM	F
Regressão	1	SQReg	$QMReg = SQReg$	$\frac{QMReg}{QMRes}$
Resíduo	$n - 2$	SQRes	$QMRes = \frac{SQRes}{n - 2}$	—
Total	$n - 1$	SQTotal	—	—

Análise de Variância (ANOVA) para a Regressão Linear Simples

A estatística F acima do quadro da ANOVA serve para testar a significância da regressão, ou seja, testar:

$$\begin{cases} H_0 : \beta_1 = 0 \\ H_1 : \beta_1 \neq 0 \end{cases}$$

Regra de Decisão: Se $F_{cal} \geq F_{\alpha}(1, n - 2) \Rightarrow$ rejeita-se H_0 .

-  Bastos, Fernando de Souza (2025). *Apostila Interativa*. Disponível online: <https://ufvest.shinyapps.io/ApostilaInterativa/>.
-  Ferreira, Eric Batista e Marcelo Silva de Oliveira (2020). *Introdução à Estatística com R*. Editora Universidade Federal de Alfenas. URL: https://www.unifal-mg.edu.br/bibliotecas/wp-content/uploads/sites/125/2021/12/32-EBR_Unifal.pdf.
-  Montgomery, D. C. e G. C Runger (2016). *Estatística Aplicada E Probabilidade Para Engenheiros*. 6ª ed. São Paulo: Grupo Gen-LTC.
-  Morettin, P.A. e W.O Bussab (2023). *Estatística básica*. 10ª ed. São Paulo: Editora Saraiva.
-  Peternelli, Luiz Alexandre (s.d.). *Apostila (EST 106)*. Formato slide Disponível no PVANet - Moodle.